



PYTHON機器學習入門

UNIT 3 : MACHINE LEARNING BASIC

授課教師：江尚瑀

OUTLINE


1. 人工智慧簡介
2. 機器學習簡介
3. 資料集



A decorative wavy line in a light green color runs vertically along the left side of the slide, separating a light beige area from the dark teal background.

WHAT IS ARTIFICIAL INTELLIGENCE?

PART 1



What is **Artificial Intelligence**?

“AI is a set of algorithms and intelligence to try to mimic human intelligence.”

How does **AI** work?

“AI works by combining large amounts of data with fast, iterative processing and intelligent algorithms, allowing the software to learn automatically from patterns or features in the data.”

系統化的工具和演算法完成**邏輯式的決策**
以達成更高**一致性與精密性**的結果

ARTIFICIAL INTELLIGENCE

Computing Machinery and Intelligence

计算机与智能

1950年

艾伦·图灵



Can Machines Think?

一套評估機器能否思考的方法: 圖靈測試 (Turing Test)


- 弱人工智慧 (Weak AI)

指人工模擬智慧，主張機器只能模擬人類具有思維的行為表現，而不是真的懂得思考(無創造力)

- 強人工智慧 (Strong AI)

跟人一樣有很廣泛的智慧(思考能力)，這是AI發展目標，尚未實現

THE HISTORY OF AI



THE HISTORY OF AI

第一波

1950-1960

失敗


符號邏輯

把人的**思考邏輯**放進電腦

由領域專家擬定決策邏輯

人類還沒辦法清楚統整自己複雜的思考過程，如何告訴電腦？

1950年代電腦發明以來便已興起關注如何以電腦解決問題



硬體儲存與效能不足



無法回答人類不知道的問題

第二波

1980-1990

失敗

專家系統

把人的**所有知識**放進電腦

由領域專家歸納經驗規則

太多難題人類無法解答、無法寫成規則、無法以程式碼表示

1980年代逐漸興起的人工智慧一個分支讓電腦能夠自行從資料中學會一套技能

如何讓電腦辨識出貓



第三波


2010-Present

機器學習

把人的**所有判斷**放進電腦


由領域專家提供歷史資料讓電腦自己歸納規則

每年史丹佛大學都會舉辦 ImageNet 競賽，讓大型企業爭奪圖像識別寶座
▶ 2015年 microsoft 準確率超越人類



資料來源：stockfeel & <人工智慧在台灣> 劉奕西整理

WHAT IS AI、ML、DL




Facebook – Yann LeCun

複雜的軟體

電腦計算能力

大量的數據

Improve



無法提出問題
無法自動建模

EXAMPLE

- 古典人工智慧

可能有個專家說：如果訊息出現，「沒事」、「我沒有生氣!!!!」...




通常就是有生氣

EXAMPLE

- 古典人工智慧


- 可能有個專家說：如果訊息出現，「沒事」、「我沒有生氣!!!!」...



EXAMPLE

- 古典人工智慧


- 簡單的說，就是規則基本上是我們告訴電腦的
- 也許比我們例子更複雜
- 也許比我們例子更簡單
- (比如說一個公式就可以算出來的問題)



EXAMPLE

- 傳統機器學習


可是有些內容，從頭到尾
不會出現這些字眼，但是
會有暗示我在生氣的訊息



EXAMPLE

- 傳統機器學習


- 基本上，我們想直接把文章放進電腦，讓他自己想辦法分辨



EXAMPLE


- 傳統機器學習

- 於是使用各種辦法例如**feature engineering**把內容的特徵找出來
 - 比例如最重要的幾個詞(!。恩 喔)出現的次數
 - 句子中出現”沒有生氣”
 - ”沒關西”前包含很多字數



EXAMPLE

- 深度學習



文字訊息



生氣

or

沒生氣




就把一篇篇我們知道答案的訊息放進去...

The end ?

EXAMPLE

- 深度學習


- 我們可能會發現這樣訓練效果不好，或是提供給我們的資訊太少，說不定應該訓練這種分類，甚至多類別型的分類



整個判斷由電腦做，所以就很仰賴**大量**且**正確**的資料

WHAT IS AI、ML、DL

Machine learning is one of AI, and deep learning is one of those machine learning techniques.




THE FUTURE OF AI

未來
2021-


很多人都說 AI 會取代我們



程式化交易



輔助診斷



自動駕駛



無人商店

至少在近幾十年內不太可能

不過我們還有92年的時間 因為2112年誕生




AI是工具輔助我們，讓我們能夠做更多事情

A decorative wavy line in a light green color runs vertically along the left side of the slide, separating a light beige area from a dark teal background.

WHAT IS MACHINE LEARNING?

PART 2



What is **Machine Learning**?

“ 機器學習是透過演算法將收集到的資料進行分類或預測模型的訓練，在未來中，當得到新的資料時，可以透過訓練出的模型進行預測 ”

“A computer program is said to learn from **experience E** with respect to some class of **tasks T** and **performance measure P**, if its performance at tasks in T, as measured by P, improves with experience E.”

--Andrew Ng

機器學習

- 舉個例子，郵件系統是如何學習呢？套用以下定義：


“A computer program is said to learn from experience E with respect to some class of tasks T and performance measure P, if its performance at tasks in T, as measured by P, improves with experience E.”




- T(任務)**：將郵件分類為垃圾或非垃圾。
- E(經驗)**：觀察目前信箱的信是把哪些種類的郵件標記為垃圾，而哪些是非垃圾。
- P(效能)**：被正確分類成垃圾或非垃圾的郵件的數量。

機器學習


- **Machine learning** 是達成**AI** 的一種方法
- 從資料當中學習出**rules** (找到一個夠好的**function**) 能解決特定的問題




Traditional Rule-based:



Machine Learning Rule-based:



資料分析的流程



機器學習

- Machine Learning is a set of the technique used for the processing of large data by developing algorithms and set of parameters to deliver the required results to the user.
- In Machine Learning data is fed and set of parameters are executed by the algorithm.

資料 + 演算法 = 機器學習

機器學習

- 資料表示的方法主有為三種模式：聲音、文字、影像



機器學習方法的種類



資料科學家會依據資料量、資料類型與運算效能等現實情況而選擇採用不同的模型

機器學習方法的方法

機器學習 Machine Learning

監督式學習 Supervised Learning

分類 Classification

二元分類
Binary Classification

多元分類
Multi Class Classification

回歸分析 Regression

非監督式學習

Unsupervised Learning

分群
Clustering



強化學習 Reinforcement Learning

Q-learning
TD

機器學習方法的細分類

機器學習方法	細分類	Features	Label (預測目標)
監督式學習	Binary Classification 二元分類	濕度、風向、風速、季節、氣壓...	只有0與1選項 (是非題) 0:不會下雨、1:會下雨
	Multi-Class Classification 多元分類		有多個選項 (選擇題) 1:晴天、2:雨天、3:陰天、4:下雪
	Regression 回歸分析		值是數值 (計算題) 溫度可能是 -50~50度的範圍
非監督式學習	Clustering 群集		無label Cluster集群分析；目的是將資料分成幾個相異性最大的群組，而群組內的相似程度最高
強化學習	Q-learning、TD (Temporal Difference)		強化學習的原理，藉由定義:動作 (Actions)、狀態 (States)、獎勵 (Rewards) 的方式，不斷訓練機器循序漸進，學會執行某項任務的演算法。


分類問題



Load the data with
`datasets.load_iris()`
There are 150 records and 4
attributes each.
There are 3 different classes

分群問題的常見例子

- 哪些消費者對農產品有相似的品味？
- 哪些觀眾喜歡同一類電影？
- 哪些型號的印表機有相似的故障？
- 這間變電所在每週的哪幾天有相似的電力需求？
- 用什麼方法可以自然地將這些文件分成五類？



增強式學習

- **RL**演算法可以用來判斷該採取的行動
- **RL**源於老鼠和人類大腦對懲罰和獎勵的反應機制。這些演算法會傾全力選出獎勵最高的選項，所以使用者必須提供一組行動選項，並告訴演算法哪些選項算好、一般、或很差的行動
- 一般而言，**RL**很適合用於需要在無人監督情況下、完成許多簡單決策自動化系統，例如電梯、電熱器、冷氣和照明系統。由於增強式學習最初被開發的目的是用來操縱機器人，任何自動物件也能使用這套演算法，像是偵查用無人機或掃地機器人。

增強式學習

- 大多數的**RL**可以在沒有資料的情況下開始分析，這些**演算法**會收集系統所產生的資料，並從試誤中不斷學習。
- 我該把廣告放在網頁何處，才能讓讀者最有機會點到它？
- 我該把溫度調高或調低一點，還是維持現狀？
- 我該再掃一次客廳還是繼續充電？
- 我現在該買入多少股？
- 看到黃燈時，我該保持當前速度、煞車還是加速？

機器學習觀念整理

- 特徵 **X**和預測目標**Y**之間存在一種關係，若找得到此種關係(**Model**), 之後帶入**X**就可以預測**Y**是什麼
 - 例如 **$Y=WX+B$** . 其中 **W,X,B,Y** 可以是個矩陣
每一列代表一筆資料，而每一行則代表其特徵
- 所謂找出關係就是去建立**Model**, 而建立**Model** 靠大量的資料進行訓練
- 找到最佳的**Model** 是一種不斷 **Optimize** 的過程

A decorative wavy line in a light green color runs vertically along the left side of the slide, separating a light beige area from a dark teal background.

HOW ML WORK WITH DATA

PART 3

機器學習解決問題的步驟

- **Step01 – 你想解決的問題**

透過觀察尋找問題，一個如果找出答案可能會對大家有幫助的問題

- **Step02 – 把問題化成函數的形式**

把問題化成解答本的形式，輸入輸出要符合格式，若無就要再調整與設計

- **Step03 – 收集歷史資料**

類似考古題概念，為避免過適或過度擬合(**overfitting**)



通常不會把所有資料給電腦學習，會切割成**70%**訓練與**30%**測試資料

機器學習解決問題的步驟

- **Step04** – 從資料中學習規則

- 讓機器透過訓練從資料學習到”知識”，提供足夠多的資料及確保資料完整性是必要的。
- 知識是一種**Model (Function)**，你可以餵資料給**Model**，機器用學會的知識來預測。
- 預測一個可能的數值或者是將資料分類(**Classification**)或者是資料分群(**Clustering**)

當我們取得資料後的步驟就是整理資料



資料

機器學習 = 資料 + 演算法


1. 沒有資料什麼都不能做
2. 有資料但品質不好 (**Dirty Data**), 可能造成 **Garbage In Garbage Out**

資料去哪收集？


1. 自行收集: 做問卷調查、設置感測器收集、..
2. 使用**Open Data** : 政府或研究機構的開放資料
 - <https://data.gov.tw>
 - [Kaggle.com](https://www.kaggle.com)
 - [UCI Machine Learning Repository](https://archive.ics.uci.edu/)
3. 各家公司提供的**API**
 - [Facebook Graph API](#), [YouTube Data API](#)
4. 網頁爬蟲程式
5. 直接向廠商購買

開放資料(OPEN DATA)的定義


- 可取得的公開資料
- 提供人們、公司，以及組織使用於
 - 創立新事業
 - 分析形態與趨勢
 - 作出資料導向決策
 - 解決複雜問題
- 開放資料的主要來源
 - 科學研究
 - 政府機關
 - 企業公司



資料的來源



資料的來源



開放源資料格式


❓ 非結構化資料檔案類型

- PDF
- Word (doc, docx)
- Notepad (txt)



! 結構化資料檔案類型

- CSV
- EXCEL (**XLS**, XLSX)
- 開放文檔格式 (**ODS**)
- WebServices (**JSON**)



```
{  
  "site_id": "新北市板橋區",  
  "village": "留侯里",  
  "birth_total": 0,  
  "death_total": 1,  
  "marry_pair": 2,  
  "divorce_pair": 2  
}
```

開放源資料平台

- 台灣政府公開資料平台

- 台灣政府資料開放平台：<https://data.gov.tw/>
- 內政部資料開放平台：<https://data.moi.gov.tw/MoiOD/default/Index.aspx>
- 文化部資料開放平台：<https://opendata.culture.tw/>
- 臺北市：<https://data.taipei/#/>
- 新北市：<https://data.ntpc.gov.tw/>
- 桃園市：<https://data.tycg.gov.tw/>
- 臺中市：<https://opendata.taichung.gov.tw/>
- 臺南市：<https://data.tainan.gov.tw/>
- 高雄市：<https://data.kcg.gov.tw/>

開放源資料平台

- 各國政府公開資料平台

- 香港政府數據中心：<https://data.gov.hk/en/>
- 英國國家數據中心：<https://data.gov.uk/>
- 日本統計局：<http://www.stat.go.jp/>
- 中國國家數據中心：<http://data.stats.gov.cn/>
- 美國政府開放資料：<https://www.data.gov/>
- 歐盟資料平台：<https://www.europeandataportal.eu/>

經典開放源資料平台

- Machine Learning Repository (UCI)



- Kaggle



開放源資料平台

- Open Data Inception - 2600+ Open Data Portals Around the World



自製資料蒐集問卷

- GoogleForms



- SurveyCake





取得資料的注意事項

- 資料是誰產生的？
 - 所有的資料都有原始產生者
 - 有時候來自個人，有時候來自政府大型組織
- 資料的產生目的為何？
 - 通常產生者會基於某些動機提供資料
 - 許多產生者仰賴資料來說服民眾、滿足外界觀感
- 資料的產生過程為何？
 - 資料產生、統計結果的正確性取決於資料蒐集與計算的過程
 - 隨意主觀猜測 **vs.** 謹慎隨機取樣

資料可能發生的問題

機器學習 = 資料 + 演算法

1. 沒有資料什麼都不能做
2. 有資料但品質不好 (**Dirty Data**), 可能造成**Garbage In Garbage Out**
 - 減少錯誤(去蕪存菁)
 - 刪除重複的記錄
 - 修正缺失值
 - 正確的範圍值
 - 修復格式 (即日期 , 文本 , 數字)

資料可能發生的問題

- 資料不完整
- 資料格式不一致
- 資料無效
- 資料重複

Dirty Data

正常的資料	2	3	4	2	1	1	4	3	2	4
部份欄位缺失	2	3	4	null	1	1	4	null	2	4
很多欄位缺失	2	3	4	null	null	null	null	null	2	4
所有欄位缺失	null	null	null	null	null	null	null	null	null	null
欄位尺度不同	2	4	yes	0.2	n	3	Hot	2	2	3
含有異常值	2	4	1	23	3	231	2	-78	4	3

DATA CLEANING 資料清洗 (去蕪存菁)

1.) 插值法



2.) 插值平均值或中位數

3.) 插值空值




DATA CLEANING (CONT.)

4.) 將名目值量化

欄位尺度不同	2	4	yes	0.2	n	3	Hot	2	2	3
			No=0 Yes=1		n=0 p=1		Hot=0.75 Cool=0.5 Cold=0.25			
欄位尺度不同	2	4	1	0.2	0	3	0.75	2	2	3

5.) 移除異常資料 (remove outlier)



68%數值分布在距離平均值有
1個標準差之內的範圍

three-sigma rule.

機器學習兩大階段

訓練階段(Training)


- 訓練階段是利用過去累積的歷史資料，可能是文字檔、資料庫、或其他來源，經過 **Feature Extraction**（特徵萃取），產生 **Feature**（資料特徵）與 **Label**（預測目標），然後經過機器學習演算法訓練後產生預測模型。

預測階段(Prediction)

- 新輸入資料(可能文字檔、資料庫、或其他來源)，經過 **Feature Extraction**（特徵萃取）產生 **Feature**（特徵），使用訓練完成的模型進行預測，最後產生預測結果。


資料集切分

- **Training Data** (訓練資料)給機器去學習，然後丟入 **Testing Data** (測試資料) 請機器判斷或預測結果



名詞定義


- 機器學習的資料在模型訓練過程中，是由特徵資料和真實類別組成
 - 特徵資料(**feature**): 例如身高、體重、腰圍、胸圍...等。
 - 真實類別(**Ground truth/label**): 資料對應的結果，如性別(男生/女生)、體脂肪率。




(time-frequency transformation)

有非常
高的變化性
(**Variety**)

資料都需要其他的方式將這些轉換成所需要的特徵資料(**feature**)



機器學習的流程




機器學習的流程 - 範例

- Image Dataset

Dataset = lots of samples
Each sample contains:


Features $X = \{x_1, x_2, \dots, x_k\}$
label=2



機器學習的流程 - 範例


- **Kaggle** 比賽

- 訓練作法



關於交叉驗證CROSS-VALIDATION

- The goal of cross-validation is to **test the model's ability to predict new data** that was not used in estimating it, in order to flag problems like overfitting or selection bias and to give an insight on how the model will generalize to an independent dataset (i.e., an unknown dataset, for instance from a real problem).



關於資料集



Training dataset
In class




Validation dataset
Homework



Test dataset
examination

關於資料集

- First split their dataset into 2 — Train and Test.
 - Randomly choose $X\%$ of their Train dataset to be the actual Train set and the remaining $(100-X)\%$ to be the Validation set,
 - where X is a fixed number(say 80%), the model is then iteratively trained and validated on these different sets.
 - If X is not fixed, use your training set to generate multiple splits of the Train and Validation sets. Ex: K-fold, Leave-one-out



For small-scale sample sets
60% training set
20% validation set

關於資料集


由於 **testing dataset** 是一組 **unseen** 的資料，所以 **testing set** 的評估結果才可以視為 **model** 上線後對真實資料的預測能力

如何只從「訓練資料(**Training data**)」就能找到一組最合適的模型參數？

- 1) 交叉驗證法(**Cross Validation**)
- 2) 拔靴驗證法(**Bootstrap Validation**)


關於交叉驗證 CROSS-VALIDATION

- Partition examples into k disjoint sets
- Now create k training sets
- Each set is union of all data except one
- So each set has $(k-1)/k$ of the original training data




LEAVE-ONE-OUT CROSS-VALIDATION

$n = 8$




Validation



Train

Model 1




K-FOLD CROSS-VALIDATION

$n = 12$


$k = 3$

Data



K-CROSS VALIDATION

3-fold cross validation:



BOOTSTRAP VALIDATION



This work by Sebastian Raschka is licensed under a
Creative Commons Attribution 4.0 International License.


In brief, the idea of the bootstrap method is to generate *new* data from a population by repeated sampling from the original dataset *with replacement*

沒選中的當Test data

如何選擇使用哪種交叉驗證？

- **Leave-one-out**
 - Use if < 100 examples (rough estimate)
 - Hold out one example, train on remaining examples
- **10-fold**
 - If have 100-1000's of examples
- **M of N fold**
 - Repeat M times
 - Divide data into N folds, do N fold cross-validation

重點歸納



- 1) Gathering data.
- 2) Cleaning data.
- 3) Feature engineering.
- 4) Defining model.
- 5) Training, test model and predicting the output.

重點歸納

- 將dataset分成Training set、Test set 與 Validation set。
training set 來訓練模型
validation set 來選擇模型（調整hyper parameter）
最終以testing set 來做最終模型效能的評估。
- 基本上你的 test set 只能用來評估最終模型，絕不能用 test set 去訓練模型或是交叉驗證。依照 model 來說 test set 就是一組 unseen 的資料，所以 test set 的評估結果才可以視為 model 上線後對真實資料的預測能力。
- 如果你的 model 在 validation set 表現不錯，但是在 test set 的表現很差，那就是過度擬合(overfitting)了。

重點歸納

- The validation set allows us to assess the current state of model learning with an **objective perspective** such as judging whether the model is overfitting
- Tune model **hyperparameters**
- The validation set will **not** be learned by the model
- The resulting score will not be an indicator of the final evaluation of the model, but by the **test set**.

重點歸納

- To make this concrete with a pseudocode sketch:

split data

```
data = ...
```

```
train, validation, test = split(data)
```

tune model hyperparameters

```
parameters = ...
```

```
for params in parameters:
```

```
    model = fit(train, params)
```

```
    skill = evaluate(model, validation)
```

evaluate final model for comparison with other models

```
model = fit(train)
```

```
skill = evaluate(model, test)
```